

Геометричні та алгебраїчні основи нейронних мереж

1 Вступ: Афінні перетворення та деформація простору

Процес розпізнавання та обробки сигналів у нейронних мережах зводиться до серії тензорних згорток (*tensor convolutions*) і матричних множень (*matrix multiplications*). Кожен прихований шар (*hidden layer*) мережі виконує композицію афінного перетворення (*affine transformation*) та нелінійного відображення (*nonlinear mapping*), що математично записується як:

$$y = \sigma(Wx + b)$$

де W — матриця ваг (*weight matrix*), x — вектор вхідних ознак (*input features*) з попереднього шару, b — вектор зміщення (*bias vector*), а σ — нелінійна функція активації (*activation function*).

1.1 Фундаментальна роль нелінійності та теорема Колмогорова-Арнольда

Присутність оператора σ є критичною. Без нелінійності суперпозиція будь-якої кількості шарів математично колапсує в одне-єдине еквівалентне афінне перетворення, оскільки композиція лінійних відображень завжди є лінійним відображенням. Афінне перетворення $Wx + b$ виконує лише базові геометричні операції у векторному просторі (обертання, масштабування, відображення та трансляцію). Усі гіперплощини (*hyperplanes*) залишаються плоскими, а паралельні лінії — паралельними.

З точки зору топології, нелінійна функція деформує многовид даних (*data manifold*), розбиваючи векторний простір і генеруючи кусково-лінійні (*piecewise linear*) або криво-лінійні границі (*decision boundaries*). Теоретичним фундаментом для такої архітектури виступає **теорема Колмогорова-Арнольда** (*Kolmogorov-Arnold representation theorem*). Вона стверджує, що будь-яку неперервну функцію n змінних можна подати як суперпозицію неперервних функцій однієї змінної та операції додавання:

$$f(x_1, \dots, x_n) = \sum_{q=0}^{2n} \Phi_q \left(\sum_{p=1}^n \phi_{q,p}(x_p) \right)$$

Модернізація теореми: від класичного результату до сучасних архітектур

Класичний запис теореми Колмогорова був згодом вдосконалений іншими математиками, що сформувало прямий алгебраїчний міст до сучасних архітектур штучних нейронних мереж¹:

- **Теорема Лоренца (універсальна зовнішня функція):** Математик Джордж Лоренц (George Lorentz) довів, що зовнішні функції Φ_q можна звести до *однієї* неперервної функції Φ , яка є спільною для всіх доданків.

¹Детальніше: <https://habr.com/ru/articles/856776/>

Зв'язок з нейромережами: Це відкриття стало строгим математичним обґрунтуванням того, чому в сучасних багат шарових перцептронах (*Multilayer Perceptrons, MLP*) усі вузли одного прихованого шару можуть використовувати *однакову* універсальну функцію активації (наприклад, ReLU, Sigmoid або Tanh). Мережі не потрібно підбирати унікальну топологічну деформацію для кожного нейрона — достатньо однієї глобальної функції.

- **Теорема Шпрехера (афінні зсуви внутрішніх функцій):** Девід Шпрехер (David Sprecher) пішов ще далі, довівши, що набір внутрішніх функцій $\phi_{q,p}$ можна замінити на одну універсальну монотонну функцію ψ , застосовуючи до її аргументів лише константи масштабування (*scaling*) та зсуву (*shifting*). Рівняння набуло вигляду:

$$f(x_1, \dots, x_n) = \sum_{q=0}^{2n} \Phi_q \left(\sum_{p=1}^n \lambda_p \psi(x_p + \epsilon_q) \right)$$

Зв'язок з нейромережами: У термінах лінійної алгебри, масштабування λ_p та зсув ϵ_q є точним еквівалентом *вагових коефіцієнтів* (weights, матриця W) та *векторів зміщення* (biases, вектор b). Шпрехер довів, що складність багатовимірної апроксимації можна перенести з пошуку складних функцій на простий пошук афінних параметрів масштабу і зсуву навколо однієї базової кривої ψ .

Аналогія з архітектурою нейронних мереж (MLP проти KAN)

Модернізація цієї теореми — зокрема, у роботах Хехт-Нільсена (Hecht-Nielsen, 1987) та в сучасній архітектурі мереж Колмогорова-Арнольда (*Kolmogorov-Arnold Networks, KAN*²) — дозволяє розглядати наведену формулу не просто як абстрактну тотожність, а як точний математичний опис ідеальної двошарової нейронної мережі прямого поширення (*feedforward neural network*). Втім, між класичними багат шаровими перцептронами (MLP) та мережами Колмогорова-Арнольда (KAN) існує фундаментальна топологічна різниця в тому, як саме кожна архітектура реалізує елементи цього рівняння:

- **Вхідний вектор x_p :** Відповідає n координатам вхідних даних (нейронам першого шару), де кожна координата обробляється незалежно і розглядається як окремий вимір простору (*spatial dimension*).
- **Внутрішні функції $\phi_{q,p}(x_p)$:** Згідно з теоремою, це нелінійні одновимірні деформації простору, що застосовуються до агрегації сигналу.
 - У мережах **KAN** це реалізується буквально: на кожному синапсі (ребрі) обчислювального графа розміщується параметризована нелінійна функція (В-сплайн).
 - У класичних **MLP** цей крок математично деградує до звичайного афінного відображення (скалярне множення на вагу $w_{q,p} \cdot x_p$), повністю втрачаючи нелінійність на етапі передачі сигналу між шарами.
- **Внутрішня сума $\sum_{p=1}^n$:** Відповідає лінійній агрегації (*linear aggregation*) сигналів у вузлах прихованого шару. Геометрично це означає проектування n -вимірного вхідного простору у простір вищої розмірності $\mathbb{R}^{2n+1}$ (оскільки індекс q змінюється від 0 до $2n$). У мережах KAN вузли (*nodes*) виконують *виключно* цю операцію підсумовування, без жодної додаткової нелінійності.

²Ziming Liu, Yixuan Wang, Sachin Vaidya, Fabian Ruehle, James Halverson, Marin Soljačić, Thomas Y. Hou, Max Tegmark. "KAN: Kolmogorov-Arnold Networks". 2024. LaTeX-джерело: <https://arxiv.org/src/2404.19756>. PDF: <https://arxiv.org/pdf/2404.19756>.

- **Зовнішні функції Φ_q :**

- У мережах **KAN** це другий шар нелінійних функцій (сплайнів), розміщених на ребрах між прихованим та вихідним шаром.
- У класичних **MLP** саме тут застосовується функція активації (наприклад, ReLU, Sigmoid чи Tanh) всередині вузла *після* агрегації. При цьому, завдяки теоремі Лоренца, замість $2n + 1$ унікальних функцій Φ_q MLP використовує єдину універсальну функцію σ для всіх нейронів шару.

- **Зовнішня сума $\sum_{q=0}^{2n}$:** Фінальна лінійна комбінація, яка колапсує багатовимірний простір $\mathbb{R}^{2n+1}$ у скалярний результат $f(x)$ на вихідному нейроні.

У класичних багат шарових перцептронах (MLP) лінійні (афінні) перетворення застосовуються на ребрах (ваги матриці W), а нелінійні універсальні функції активації Φ (за Лоренцом) розташовуються у вузлах. Сучасна архітектура KAN концептуально «перевертає» цю геометрію: спираючись на оригінальну формулу Колмогорова-Арнольда, вона відмовляється від фіксованих функцій активації у вузлах. Натомість усі нелінійні функції $\phi_{q,p}$ (які реалізуються як параметризовані B-сплайни з навчальними коефіцієнтами) розташовуються *безпосередньо на ребрах* графа обчислень. Вузли у KAN виконують лише операцію додавання (лінійну агрегацію).

З геометричної точки зору, замість того, щоб проектувати простір гіперплощинами та деформувати його у вузлах (як в MLP), KAN деформує кожен одновимірний базисний напрямок безпосередньо під час передачі сигналу по тензорному ребру.

Поглиблення: Алгебраїчна реалізація через B-сплайни

У мережах KAN кожна одновимірна функція на ребрі $\phi(x)$ не є фіксованою, а формується як лінійна комбінація елементів локального базису (*local basis*):

$$\phi(x) = \sum_{i=1}^k c_i B_i(x)$$

де $B_i(x)$ — базисні функції сплайна заданого степеня, а c_i — параметри (ваги), що оптимізуються. З точки зору лінійної алгебри, це елегантний перехід: задача пошуку довільної нелінійної топологічної деформації у нескінченновимірному функціональному просторі зводиться до пошуку скінченного вектора коефіцієнтів $\mathbf{c} \in \mathbb{R}^k$ у лінійному підпросторі (*linear subspace*), натягнутому на базис $\{B_i\}$.

Ключовий внесок цієї роботи полягає в узагальненні класичного зображення Колмогорова-Арнольда — яке відповідає лише дворівневій KAN-мережі форми $[n, 2n + 1, 1]$ — на довільну ширину та глибину: подібно до того, як шари MLP накладаються один на одний, шари KAN також складаються у глибші мережі. Формально це записується як композиція шар-матриць одновимірних функцій Φ_L :

$$\text{KAN}(x) = (\Phi_{L-1} \circ \Phi_{L-2} \circ \dots \circ \Phi_0)(x),$$

що структурно контрастує з класичним MLP, який чергує афінні перетворення з фіксованою нелінійністю:

$$\text{MLP}(x) = (W_{L-1} \circ \sigma \circ W_{L-2} \circ \sigma \circ \dots \circ W_0)(x).$$

Отже, теорема Колмогорова-Арнольда геометрично доводить, що простір будь-яких складних багатовимірних функцій можна звести до композиції одновимірних деформацій та лінійних проєкцій: у контексті машинного навчання це є строгою гарантією того, що

двошарова мережа з достатньою кількістю прихованих нейронів (мінімум $2n + 1$) здатна апроксимувати довільну неперервну функцію на обмеженій області. Проте саме мережі KAN реалізують цю геометрію найбільш точно та природно: вони буквально розміщують передбачені теоремою одновимірні функції на ребрах графа, тоді як класичні MLP лише наближено відтворюють цю структуру за допомогою фіксованих активацій у вузлах та лінійних ваг на ребрах.

2 Класифікація нелінійних відображень

З точки зору лінійної алгебри, нелінійне відображення $\sigma : \mathbb{R}^n \rightarrow \mathbb{R}^m$ може мати різну структуру. Розглянемо три основні геометричні класи:

2.1 1. Ізотропні покомпонентні відображення (Element-wise / Diagonal maps)

Тут σ — це одна й та сама скалярна функція $f : \mathbb{R} \rightarrow \mathbb{R}$, яка застосовується до кожної координати вектора $\mathbf{z} \in \mathbb{R}^n$ абсолютно незалежно:

$$\sigma(\mathbf{z}) = \begin{pmatrix} f(z_1) \\ f(z_2) \\ \vdots \\ f(z_n) \end{pmatrix}$$

Геометричний зміст: Деформація простору відбувається виключно вздовж кожного базисного вектора окремо. Взаємодії між вимірами на етапі активації немає (за змішування координат відповідає виключно лінійний оператор W).

2.2 2. Глобальні векторні відображення (Coupled coordinates)

Значення кожної вихідної координати залежить від усього вхідного вектора. Тут σ є вектор-функцією, яку неможливо розділити. Прикладом є відображення Softmax:

$$\sigma(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}}$$

Геометричний зміст: Це гладке відображення (*smooth mapping*) бере весь векторний простір $\mathbb{R}^n$ і проектує його у внутрішність $(n - 1)$ -вимірного стандартного симплекса (*standard simplex*). Через спільний знаменник координати стають лінійно залежними ($\sum \sigma_i = 1$), що кардинально змінює топологію простору.

2.3 3. Анізотропні (параметричні) відображення (Parametric maps)

Функція діє покомпонентно, але має різну форму для різних базисних напрямків. Наприклад, у Parametric ReLU (PReLU):

$$\sigma(\mathbf{z})_i = \max(0, z_i) + \alpha_i \min(0, z_i)$$

де вектор $\alpha \in \mathbb{R}^n$ містить унікальні коефіцієнти розтягування/стискування для кожної i -тої осі. **Геометричний зміст:** Гіперплощини простору деформуються (згинаються) з різним ступенем жорсткості для кожного виміру. Простір зазнає анізотропної кусково-лінійної деформації (*anisotropic piecewise linear deformation*).

3 Лінійна алгебра: Згортання тензорів (Tensor Contraction)

У машинному зорі (*computer vision*) вхідне зображення є тензором третього рангу (*third-order tensor*) $\mathcal{X} \in \mathbb{R}^{H \times W \times C}$, де H, W — просторові розміри (*spatial dimensions*), а C — кількість каналів. Ядро згортки (*convolutional kernel / filter*) — це тензор четвертого рангу $\mathcal{W} \in \mathbb{R}^{K \times K \times C \times M}$, де K — просторовий розмір фільтра, а M — кількість вихідних каналів.




Рис. 1: Операція згортки матриці та ядра. Джерело: DOU

Математично, для кожного пікселя вихідного тензора $\mathcal{Y} \in \mathbb{R}^{H' \times W' \times M}$ (який формує карту ознак — *feature map*), обчислюється скалярний добуток Фробеніуса (*Frobenius inner product*) (згортання за трьома індексами) між локальним патчем зображення (*receptive field*) та фільтром:

$$\mathcal{Y}_{i,j,m} = \sum_{c=1}^C \sum_{u=0}^{K-1} \sum_{v=0}^{K-1} \mathcal{X}_{i+u,j+v,c} \cdot \mathcal{W}_{u,v,c,m}$$

Тут ми бачимо класичну афінну трансформацію (до результату також додається вектор зміщення $\mathbf{b} \in \mathbb{R}^M$), яка проектує підпростір розмірності $K \times K \times C$ у скаляр.

Поглиблення: Тензорне числення та угода Ейнштейна

У строгому математичному апараті диференціальної геометрії використовується угода Ейнштейна про підсумовування (*Einstein summation convention*) (де сума береться за індексами, що повторюються зверху і знизу), що дозволяє записати операцію згортки без громіздких знаків суми.

Нехай $X_{x,y}^c$ — компоненти вхідного тензора (верхній індекс c — контраваріантна компонента каналу, нижні x, y — коваріантні просторові координати), а $W_{c,u,v}^m$ — компоненти тензора ваг (m — вихідний канал). Тоді операція локальної згортки (*local convolution*) набуває вигляду:

$$Y_{i,j}^m = X_{i+u,j+v}^c W_{c,u,v}^m + b^m$$

Підсумовування за індексами c та u, v мається на увазі автоматично. Це чітко демонструє, що згортка є класичним згортанням тензорів за відповідними коваріантними та контраваріантними індексами.

3.1 Матрична репрезентація (Тоепліцеві матриці та `im2col`)

Апаратно обчислювати багатовимірні суми неефективно, тому тензорна згортка зводиться до одного матричного множення (*General Matrix Multiply, GEMM*) через ізоморфізм просторів.

Якщо розглядати одновимірну згортку, то ядро діє як лінійний оператор, матриця якого має структуру матриці Тоепліца (*Toeplitz matrix*) (діагоналі містять однакові елементи). Для двовимірного випадку (зображення) це буде двічі блочно-циркулянтна матриця з Тоепліцевими блоками.

На практиці застосовується операція перетворення `im2col` (*image to column*):

1. Локальні патчі тензора $\mathcal{X}$ (розміром $K \times K \times C$) розгортаються у вектори (*flattened*) і записуються як стовпці матриці $\mathbf{X}_{col}$.
2. Тензор ваг $\mathcal{W}$ розгортається у матрицю $\mathbf{W}_{row}$.
3. Згортка виконується як стандартне множення матриць:

$$\mathbf{Y} = \mathbf{W}_{row} \mathbf{X}_{col}$$

Таким чином, згортка — це лінійне відображення $\mathbb{R}^{K^2 C} \rightarrow \mathbb{R}^M$, яке застосовується до кожного локального патча зображення.

3.2 Диференціальна геометрія: Згортка на многовидах та еквіваріантність

У класичному машинному зорі ми працюємо на плоскому евклідовому просторі $\mathbb{R}^2$ або дискретній ґратці $\mathbb{Z}^2$. Операція згортки є еквіваріантною (трансляційно-інваріантною — *translation equivariant*) відносно групи зсувів $T(2)$. Тобто, якщо зсунути об'єкт на зображенні, карта ознак (*feature map*) зсунеться аналогічно: $f(T_g x) = T_g f(x)$.

Проте, якщо подивитися на це через призму диференціальної геометрії, ми можемо узагальнити згортку для довільних многовидів (*manifolds*) (наприклад, сфера S^2 для панорамних камер) або груп Лі (*Lie groups*) (наприклад, $SE(2)$ для розпізнавання об'єктів незалежно від їхнього кута повороту).

У цьому контексті:

- Вхідне зображення розглядається як функція (або переріз векторного розшарування) на гладкому многовиді (*smooth manifold*) M .
- Згортка формалізується через інтегрування за мірою Хаара (*Haar measure*) на топологічній групі G :

$$[\mathcal{W} \star \mathcal{X}](g) = \int_G \mathcal{W}(h^{-1}g) \mathcal{X}(h) d\mu(h)$$

де $g, h \in G$.

- У геометричному глибокому навчанні (*Geometric Deep Learning*) ядро згортки переміщується по многовиді за допомогою паралельного перенесення (*parallel transport*) уздовж геодезичних, враховуючи кривизну простору (зв'язність Леві-Чівіті — *Levi-Civita connection*), щоб порівнювати тензори у різних дотичних просторах (*tangent spaces*).

Поглиблення: Перерізи розшарувань на групах Лі

У строгому сенсі диференціальної геометрії, вхідне зображення та карти ознак є не просто функціями, а **перерізами векторних розшарувань** (sections of vector bundles) над базовим гладким многовидом M . Якщо $\mathcal{E} \xrightarrow{\pi} M$ — векторне розшарування, то карта ознак $f \in \Gamma(M, \mathcal{E})$.

Еквіваріантність згортки вимагає, щоб дія групи Лі G на базовому многовиді M коректно піднімалася (lift) до дії на просторі перерізів. Якщо L_g — оператор лінійного представлення групи, то еквіваріантність формалізується як комутативність: $\mathcal{K} \star (L_g f) = L_g(\mathcal{K} \star f)$.

Джерела

- Ziming Liu, Yixuan Wang, Sachin Vaidya, Fabian Ruehle, James Halverson, Marin Soljačić, Thomas Y. Hou, Max Tegmark. *KAN: Kolmogorov-Arnold Networks*. arXiv:2404.19756 [cs.LG], 2024 (прийнято на ICLR 2025). LaTeX-джерело: <https://arxiv.org/src/2404.19756>. PDF: <https://arxiv.org/pdf/2404.19756>.
- Sqrudj. *KAN: Kolmogorov–Arnold Networks* (повний переклад статті). Хабр, 2024. <https://habr.com/ru/articles/856776/>.